

ПРАВИТЕЛЬСТВО РОССИЙСКОЙ ФЕДЕРАЦИИ
ФГАОУ ВО НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет компьютерных наук
Образовательная программа «Прикладная математика и информатика»

Отчёт об исследовательском проекте на тему:

**Сравнение архитектур CNN и трансформеров для классификации
заболеваний растений с применением трансферного обучения
и адаптации доменов**

Выполнил студент:

группы #БПМИ231, 3 курса

Резниченко Александр Дмитриевич

Принял руководитель проекта:

Ершов Егор Иванович

к. ф.-м. н.

Старший научный сотрудник сектора 11.1

«Синтеза и репродукции цвета» ИППИ РАН

Содержание

Аннотация	3
Ключевые слова	3
1 Введение	4
1.1 Цель и исследовательские вопросы	4
1.2 Задачи работы	5
2 Обзор литературы	6
2.1 Данные для распознавания заболеваний растений	6
2.2 Свёрточные и трансформерные сегментаторы	6
2.3 Плотные признаки DINOv3	6
2.4 Сегментация, управляемая подсказками, и адаптация SAM	7
2.5 Отбор данных при ограниченном бюджете	7
3 Постановка задачи и протокол оценки	8
4 Методика экспериментов	9
4.1 Линия повышения качества	9
4.2 Линия минимизации разметки	11
5 Результаты	11
5.1 Сравнение CNN и DINOv3	12
5.2 Абляции адаптации DINOv3	13
5.3 Влияние разрешения и сетки оценки	15
5.4 Ручная разметка трудных случаев	15
5.5 SAM без дообучения	16
5.6 Ложные тревоги на здоровых растениях	17
5.7 Эффективность использования разметки	17
6 Обсуждение и практические рекомендации	19
7 Ограничения	22
8 Заключение	22
Список использованных источников	23

Аннотация

Работа посвящена переносу свёрточных и трансформерных моделей на бинарную семантическую сегментацию поражённых областей растений в условиях ограниченной пиксельной разметки. Исследуются две взаимосвязанные стороны задачи: качество адаптации модели и количество размеченных изображений, необходимое для его достижения. Эксперименты проводятся на PlantSeg с фиксированными разбиениями; модели и гиперпараметры выбираются по валидационной выборке, а основной метрикой служит IoU класса поражения.

Построена воспроизводимая процедура экспериментов с DINOv3, DeepLabV3-ResNet50 и Segment Anything Model (SAM). На валидационной выборке полностью дообучаемый DeepLabV3 получил 0.6690 ± 0.0008 IoU поражения против 0.6519 ± 0.0062 у DINOv3 с замороженным энкодером. При согласованном линейном зондировании замороженных энкодеров направление результата изменилось: DINOv3 получил 0.5990 ± 0.0011 против 0.3860 ± 0.0044 у ResNet-50. Подтверждающая тестовая серия сохранила оба направления результата. Для DINOv3 замена линейного декодера свёрточным дала прирост 0.0401, тогда как эффект чтения четырёх слоёв был мал и зависел от запуска. Увеличение входа с 384 до 768 px повысило IoU на 0.0129, однако 95%-й бутстреп-интервал включал ноль. SAM без дообучения даже с рамкой из эталонной разметки не стал готовой системой поиска заболевания. При ограничении разметки 25% масок дали примерно 95% качества полной выборки. Стратификация практически совпала со случайным отбором, жадное покрытие пространства признаков оказалось хуже из-за перевеса выбросов, а представители кластеров лишь вернули качество к уровню простых баз. Результаты показывают, что способ адаптации и состав размеченных данных не менее важны, чем семейство архитектур.

Ключевые слова

Семантическая сегментация, заболевания растений, свёрточные нейронные сети, трансформеры, DINOv3, Segment Anything, перенос обучения, отбор данных, ограниченная разметка.

1 Введение

Заболевания растений снижают урожайность и качество сельскохозяйственной продукции. Их визуальная диагностика требует не только определить наличие патологии, но и локализовать поражённую область. Классификатор изображения не даёт такой локальной информации, тогда как семантическая сегментация назначает метку каждому пикселю и может использоваться как основа для количественной оценки поражения и последующего принятия решений. Поэтому в рамках формального названия работы сегментация рассматривается как классификация на уровне пикселей.

Бинарная постановка выбрана также из содержательного предположения о переносе: базовые модели общего назначения (foundation models) могут выделять визуально отличающиеся поражённые области, но не обязаны различать узкоспециализированные классы фитопатологий, слабо представленные в данных их предобучения. Поэтому сначала проверяется базовая способность переносимых признаков отделять поражение от фона. Это предположение не проверяется данной бинарной постановкой полностью: сравнение многоклассового распознавания 115 заболеваний и способов доменной адаптации остаётся самостоятельной задачей будущей работы.

Создание пиксельных масок значительно дороже присвоения изображению одной метки. Поэтому практический интерес представляет не только максимально точная модель, но и зависимость её качества от объёма разметки. Масштабные самоконтролируемые модели, в частности DINOv3 [1], дают плотные визуальные признаки без предварительного обучения на целевой разметке и тем самым могут быть особенно полезны в малых выборках. Другой класс крупных предобученных моделей представляет SAM [2]: модель строит маску по геометрической подсказке, но сама по себе не знает семантику заболевания. Эти свойства мотивируют совместное исследование адаптации моделей и выбора данных.

1.1 Цель и исследовательские вопросы

Цель работы — определить, как семейство модели, способ его адаптации и объём пиксельной разметки влияют на качество переноса свёрточных и трансформерных моделей на бинарную сегментацию поражённых областей растений в PlantSeg.

Работа отвечает на следующие исследовательские вопросы.

- RQ1. Как DeepLabV3 с энкодером ResNet-50 соотносится с DINOv3 в практически используемых режимах переноса и при согласованном линейном зондировании, и какие компоненты адаптации DINOv3 дают устойчивый вклад в качество?
- RQ2. Как разрешение входа и площадь поражения влияют на ошибки моделей и что показывает SAM без дообучения при подсказках из эталонной разметки?
- RQ3. Можно ли по замороженным признакам DINOv3 выбрать подмножество PlantSeg, которое при том же числе размеченных изображений превосходит случайный отбор,

и какая доля данных необходима для достижения заданной части качества обучения на полной выборке?

1.2 Задачи работы

Для достижения цели необходимо решить следующие задачи:

1. подготовить данные PlantSeg и зафиксировать воспроизводимый протокол бинарной сегментации: разбиение выборки, преобразование масок, предобработку, правила выбора контрольной точки и расчёта метрик;
2. сравнить практически применимые режимы переноса: полное дообучение DeepLabV3-ResNet50 и обучение декодера при замороженном энкодере DINOv3; отдельно измерить вклад ImageNet-инициализации DeepLabV3;
3. сравнить качество признаков ResNet-50 и DINOv3 независимо от способа адаптации, заморозив оба энкодера и обучив для них одинаковый линейный декодер на общей пространственной сетке;
4. измерить, как на качество DINOv3 влияют тип декодера, использование одного или нескольких слоёв энкодера, разрешение входа и повышенный вес изображений с малыми поражениями;
5. оценить SAM ViT-B без дообучения с точечной подсказкой и рамкой, полученными из эталонной маски, как диагностический режим сегментации по подсказке, а не как автоматический поиск заболевания;
6. построить кривые зависимости качества от доли размеченных изображений и оценить, какая доля данных сохраняет 95% IoU поражения модели, обученной на полной выборке; сравнить случайный, стратифицированный, жадный выбор наиболее удалённых объектов и выбор представителей кластеров при бюджетах 10 и 25%;
7. проверить устойчивость основных результатов в повторных запусках и с помощью парного бутстрепа, затем оценить зафиксированные конфигурации на тестовой выборке;
8. разобрать характерные ошибки моделей, измерить ложные срабатывания на внешнем наборе здоровых растений и сравнить вычислительные затраты.

Вклад работы состоит не в воспроизведении одной опубликованной архитектуры, а в согласованном сравнительном исследовании CNN, DINOv3, SAM и методов отбора разметки в едином протоколе PlantSeg. Итогом являются не только лучшие метрики, но и кривые «качество—объём разметки», анализ режимов отказа и рекомендации по выбору метода при заданном бюджете.

2 Обзор литературы

2.1 Данные для распознавания заболеваний растений

PlantVillage широко используется для классификации заболеваний растений [3]. Его изображения преимущественно получены в контролируемых условиях и имеют метки на уровне изображения, что ограничивает применимость набора к локализации поражений. PlantSeg [4, 5], напротив, содержит изображения из неконтролируемых источников и пиксельные маски поражённых частей. В данной работе используется исследовательская версия PlantSeg v3 с 7916 обучающими, 1247 валидационными и 2295 тестовыми изображениями. Исходные 115 меток заболеваний сворачиваются в один целевой класс, поскольку основной вопрос работы относится к локализации поражения, а не к распознаванию его типа.

Используемая версия PlantSeg не содержит здоровых изображений. Поэтому для отдельной оценки ложных тревог взята официальная тестовая часть здоровых классов PlantWild v1 [6]: 1556 изображений 30 видов растений. Она не смешивается с основной валидацией, поскольку представляет внешний домен без пиксельной разметки. Опубликованные базовые результаты PlantSeg включают как свёрточные DeepLabV3/DeepLabV3+, так и трансформерные и гибридные модели, однако их многоклассовое mIoU нельзя напрямую сопоставлять с бинарным IoU этой работы.

2.2 Свёрточные и трансформерные сегментаторы

DeepLabV3 применяет разреженные свёртки с расширением и пирамиду контекстных масштабов, сохраняя поле зрения без чрезмерного уменьшения карты признаков [7]. DeepLabV3+ добавляет энкодер-декодер для уточнения границ [8]. В работе DeepLabV3 с ResNet-50 выбран как свёрточная точка отсчёта: это распространённая архитектура, для которой можно явно сравнить случайную и ImageNet-инициализацию.

В отличие от DeepLabV3, DINOv3 сам по себе не предсказывает маску: это предобученная модель для извлечения признаков изображения. В экспериментах энкодер DINOv3 заморожен, а маску по его признакам строит отдельный обучаемый декодер. Поэтому для DINOv3 в работе сравниваются прежде всего разные варианты декодера.

2.3 Плотные признаки DINOv3

DINOv3 — семейство самоконтролируемых визуальных энкодеров, обученных на масштабной коллекции изображений [1]. Якорная регуляризация матрицы Грама (Gram anchoring) направлена на сохранение качества локальных признаков при длительном обучении, что делает модель естественным энкодером для попиксельного предсказания. Если энкодер заморожен и обучается только небольшой декодер, результат в большей степени отражает качество признаков, полученных при предобучении. При полном дообучении этот вклад нельзя отделить от адаптации всей модели к PlantSeg.

DINOv2 ранее показал, что самоконтролируемое предобучение на большой курированной коллекции даёт переносимые признаки для задач уровня изображения и пикселя [9]. DINOv3 развивает эту линию и уделяет отдельное внимание сохранению плотных локальных признаков при масштабировании обучения. В этой работе проверяется, насколько признаки замороженного DINOv3 подходят для сегментации по сравнению с полностью дообучаемой CNN.

Для сегментации важны одновременно семантика глубоких слоёв и пространственные детали промежуточных слоёв. Поэтому в работе сравниваются линейное чтение последнего слоя, нелинейный свёрточный декодер и декодер, объединяющий признаки нескольких блоков трансформера. Такое сравнение отвечает на вопрос, достаточно ли линейного чтения замороженного представления или нужен более выразительный декодер. Сам энкодер DINOv3 в этих абляциях не размораживается.

2.4 Сегментация, управляемая подсказками, и адаптация SAM

SAM состоит из энкодера изображения, энкодера подсказок и лёгкого декодера масок и обучен выдавать маску по точкам, рамке или маске-подсказке [2]. Поэтому режим SAM без дообучения требует точного протокола. Рамка, построенная из истинной маски, использует скрытую разметку и представляет верхнюю оценку качества по подсказке, а не автоматическую сегментацию заболевания без примеров. Автоматический генератор масок также не решает семантический выбор: он строит несколько масок, но не указывает, какая из них соответствует поражению.

Работы по адаптации SAM показывают, что на специализированных доменах можно обучать декодер масок или добавлять небольшие адаптеры вместо полного обновления энкодера [10, 11]. HQ-SAM уточняет сложные границы посредством дополнительного выходного токена [12], PerSAM использует одно референсное изображение для персонализации [13], а SAM 2 переносит управляемую подсказками сегментацию на изображения и видео [14]. Эти варианты подтверждают, что способ адаптации важен, но их исследование образует отдельную крупную ветку. В данной работе SAM используется только для строгой диагностики качества исходной модели по подсказкам.

2.5 Отбор данных при ограниченном бюджете

Случайное подмножество является обязательной точкой отсчёта, но может содержать избыточно похожие изображения. Подход на основе репрезентативного подмножества (core-set) формулирует выбор разметки как покрытие пространства признаков; жадный алгоритм k-центров последовательно добавляет наиболее удалённый от уже выбранных объект [15]. В практической реализации это соответствует жадному отбору наиболее удалённых объектов (farthest-first). Кластерные методы решают близкую, но не идентичную задачу: методы k-средних или k-медоидов выбирают типичных представителей плотных областей, тогда как жадный отбор сильнее поощряет разнообразие и выбросы. TypiClust

показывает, что типичность особенно важна в режиме холодного старта и малого бюджета [16].

Сильная случайная выборка особенно важна для корректности вывода. Mittal и соавторы показали чувствительность методов активного обучения к процедуре обучения и лишь небольшой выигрыш относительно случайного отбора, в том числе для сегментации [17]. Munjal и соавторы при контроле источников случайности также получили неустойчивые преимущества разных эвристик и рекомендуют повторные запуски в едином протоколе [18]. Поэтому различия порядка тысячных в данной работе не интерпретируются как победа метода.

Для сегментации возможен выбор изображений, регионов или пикселей. В основной части этой работы единицей бюджета является полностью размеченное изображение: это соответствует структуре PlantSeg и позволяет однозначно сравнивать методы. Для каждого изображения признаки его участков, полученные DINOv3, усредняются в один вектор. По этим векторам изображения выбираются до использования разметки. Однако различия между векторами могут быть связаны с фоном, ракурсом или видом растения, а не с характером поражения. Поэтому визуально разнообразная выборка не обязательно оказывается наиболее полезной для обучения сегментации.

3 Постановка задачи и протокол оценки

Пусть x_i — RGB-изображение, а $y_i(p) \in \{0, 1\}$ — метка пикселя p , где 1 соответствует размеченной поражённой области. Модель с параметрами θ строит вероятность $P_\theta(y_i(p) = 1 \mid x_i)$. Основная метрика — IoU поражения

$$\text{IoU}_{\text{dis}} = \frac{TP}{TP + FP + FN}, \quad (1)$$

где TP , FP и FN накапливаются по всему разбиению. В отличие от pixel accuracy, метрика (1) не получает выгоды от большого числа правильно классифицированных пикселей фона.

Дополнительно приводятся среднее IoU двух классов, коэффициент Dice, точность, полнота, средняя точность по пикселям (pixel AP) и среднее IoU поражения по изображениям. Последнее важно для анализа малых масок: агрегированное по всему разбиению IoU сильнее взвешивает изображения с большой площадью поражения. На внешнем наборе здоровых растений истинная площадь поражения по определению равна нулю, поэтому IoU неинформативно. Вместо него измеряется доля изображения, помеченная моделью как поражение, и доля ложных тревог при порогах площади 0.1, 0.5, 1 и 5%. Эти числа характеризуют поведение при смене набора данных, но не входят в выбор лучшей контрольной точки.

Обучающее разбиение используется для оптимизации параметров, валидационное — для выбора гиперпараметров, контрольных точек и порогов. Тестовое разбиение не участ-

вует ни в одном из этих решений. Выбор моделей и основные выводы строятся по валидационной выборке. После их фиксации две ключевые пары моделей оценены на тестовой выборке по заранее опубликованному протоколу без последующей настройки. В подтверждающей серии обе практические модели получают вход 384×384 ; метрики считаются как на масштабированной сетке 384×384 , так и после интерполяции предсказаний к исходному разрешению аннотаций. Изменяется только сетка оценки, а не вход модели. Ключевые конфигурации повторяются с тремя начальными значениями генератора; для парных сравнений дополнительно применяется бутстреп по 1247 валидационным или 2295 тестовым изображениям с 10 000 повторов. В каждой итерации одни и те же индексы изображений выбираются с возвращением для обеих моделей, их TP , FP и FN суммируются, после чего вычисляется разность агрегированных IoU. Границами 95%-го интервала служат квантили 2.5 и 97.5% распределения разностей.

В эксперименте с ограниченной разметкой выбирается подмножество $S_b \subset D_{\text{train}}$ размера b . Для каждого метода строится кривая $Q(b)$, где Q — валидационное IoU_{dis} . Основными сводными характеристиками служат площадь под нормированной кривой качества по логарифму бюджета без общей точки 100% и минимальная доля данных, достигающая 95% качества модели, обученной на полном наборе. Число шагов оптимизатора и правило выбора контрольной точки фиксируются, чтобы малые подмножества не проигрывали только из-за меньшего числа обновлений. Для бюджетов $b_1 < \dots < b_K$ используется трапецидальная оценка

$$\text{AULC}_{\log} = \frac{1}{\log b_K - \log b_1} \sum_{k=1}^{K-1} \frac{q_k + q_{k+1}}{2} (\log b_{k+1} - \log b_k), \quad q_k = \frac{Q(b_k)}{Q(100\%)}. \quad (2)$$

В сравнениях берутся интервалы 1–50% и 1–25%, поэтому общая для методов точка $b = 100\%$ нормирует качество, но не добавляет площадь.

4 Методика экспериментов

4.1 Линия повышения качества

В качестве свёрточной точки отсчёта используется DeepLabV3 с ResNet-50: сравниваются перенос энкодера, предварительно обученного на ImageNet, и случайная инициализация. Эти два запуска различаются только инициализацией; расписание скорости обучения и остальные гиперпараметры совпадают. Изображения, разбиения и метрики совпадают с DINOv3. В экспериментах используется DINOv3 ViT-B/16 с замороженным энкодером. Для неё сравниваются:

1. линейный и свёрточный декодеры;
2. признаки последнего слоя и объединение блоков 3, 6, 9 и 12 при одном 30-эпоховом обучении с косинусным затуханием скорости обучения;

3. разрешения 384, 512 и 768 пикселей;
4. увеличение веса изображений с малыми поражениями.

Во всех итоговых контролируемых сериях используется AdamW с перекрёстной энтропией, весовым затуханием 10^{-4} , случайным горизонтальным отражением и вычислениями смешанной точности bfloat16. Все итоговые запуски выполнены на одной NVIDIA A100-SXM4 с 80 ГиБ памяти. Финальные сравнения обучаются 30 эпох с косинусным затуханием скорости обучения; ранние разведочные абляции линейного и свёрточного декодеров ограничены 10 эпохами и отмечены отдельно в результатах. Многослойный декодер DINOv3 объединяет признаки блоков 3, 6, 9 и 12, после чего применяет свёртку 3×3 до 256 каналов, GELU и свёртку 1×1 до двух классов. В нём обучаются 7.08 из 92.74 млн параметров; энкодер заморожен. В DeepLabV3 обучаются все 39.63 млн параметров. Обе модели основного межсемейного сравнения получают растянутый до 384×384 вход. Размер пакета 16 сохранён при всех трёх разрешениях отдельной абляции DINOv3, поэтому число обновлений параметров декодера также совпадает. При размере фрагмента 16 пикселей этим разрешениям соответствуют сетки признаков 24×24 , 32×32 и 48×48 .

Основное межсемейное сравнение выше намеренно рассматривает два практически полезных, но разных режима переноса: полное дообучение CNN и обучение декодера при замороженном трансформере. Чтобы отдельно сопоставить качество предобученных признаков, проводится дополнительное линейное зондирование. Энкодеры ResNet-50 и DINOv3 ViT-B/16 замораживаются, их признаки приводятся к общей сетке 24×24 , а обучаемая часть состоит только из свёртки 1×1 на два класса. Для обеих моделей используются одинаковые данные, аугментация, размер пакета, 30 эпох, AdamW с начальной скоростью 10^{-3} и косинусное затухание до 10^{-5} . Этот контроль выравнивает режим адаптации и пространственную сетку, но не делает предобучение идентичным: ResNet-50 обучен с учителем на ImageNet, тогда как DINOv3 обучен самоконтролируемо на более крупном наборе изображений. Обе реализации используют одинаковую нормализацию ImageNet; различия предобработки в этот контроль не входят. Чтобы проверить чувствительность к понижению пространственного разрешения, ResNet-50 дополнительно обучается с той же головой на исходной сетке его признаков 48×48 ; этот вариант не участвует в выборе основной постановки.

Таблица 4.1 – Основные параметры обучения сравниваемых моделей.

Модель	Размер	Пакет	Нач. скорость	Мин. скорость
DINOv3 ViT-B/16	384	16	10^{-3}	10^{-5}
DINOv3 ViT-B/16	512	16	10^{-3}	10^{-5}
DINOv3 ViT-B/16	768	16	10^{-3}	10^{-5}
DeepLabV3-ResNet50, ImageNet	384	16	10^{-4}	10^{-6}
DeepLabV3-ResNet50, случайная	384	16	10^{-4}	10^{-6}

Для SAM без дообучения измеряется качество с двумя видами подсказок из эталонной маски. Положительная точка выбирается как ближайший пиксель поражения к

центроиду всей маски. Одна рамка охватывает объединение всех связных компонент поражения. Из трёх предложенных SAM масок выбирается вариант с наибольшим прогнозируемым качеством: вместе с каждой маской SAM выдаёт оценку её ожидаемого IoU, и выбирается маска с максимальной оценкой. Эталонная маска при выборе не используется и нужна только для последующего расчёта метрик. Такой эксперимент измеряет качество по подсказке и не сравнивается напрямую с автоматическим поиском заболевания.

4.2 Линия минимизации разметки

Из замороженных DINOv3-признаков фрагментов строится один нормированный дескриптор на изображение. Случайный, стратифицированный и жадный методы сравниваются при бюджетах 1, 5, 10, 25, 50 и 100%, а более дорогой кластерный контроль — при 10 и 25%. Рассматриваются:

1. равномерный случайный отбор;
2. стратифицированный случайный отбор по метке заболевания;
3. жадный отбор наиболее удалённых объектов для покрытия пространства признаков;
4. ближайшие к центрам представители сферического k -means.

Для сферического k -means дескрипторы нормируются по L_2 , центры пересчитываются 30 итераций, а лучший вариант выбирается из трёх случайных инициализаций. Для каждого кластера в подмножество включается реальное изображение, ближайшее к его центру по косинусному сходству. В отличие от методов, задающих единый порядок объектов, кластеры для бюджетов 10 и 25% строятся независимо, поэтому эти два подмножества не обязаны быть вложенными.

Основное сравнение проводится для наиболее устойчивой конфигурации DINOv3. Для всех малых подмножеств за эпоху обрабатывается одинаковое число примеров с повторной выборкой, поэтому число шагов оптимизатора не зависит от бюджета.

5 Результаты

Если не указано иное, приведённые ниже эксперименты используют изображения 384×384 , растянутые до квадрата, и метрики на этой же сетке. В отдельном сравнении разрешений выходные оценки моделей интерполируются на исходную сетку каждой аннотации, чтобы размер входа не менял дискретизацию целевой маски. Все абляции и контрольные точки выбираются по валидационной выборке. Тестовые метрики приводятся только для двух заранее зафиксированных итоговых сравнений и явно помечаются как подтверждающая оценка.

Таблица 5.1 – Сравнение семейств моделей на валидационной выборке; среднее и выборочное стандартное отклонение IoU поражения по трём запускам.

Модель	Режим переноса	Всего, млн	Обучаемых, млн	IoU поражения
DeerLabV3-R50	ImageNet, полное дообучение	39.63	39.63	0.6690 ± 0.0008
DINOv3 ViT-B/16	замороженный энкодер	92.74	7.08	0.6519 ± 0.0062

5.1 Сравнение CNN и DINOv3

На валидационной выборке DeerLabV3 превосходит DINOv3 в каждой паре запусков с одинаковым начальным значением генератора; разность средних равна 0.0171. Одновременно DINOv3 обучает в 5.6 раза меньше параметров. Поскольку CNN дообучается целиком, а энкодер DINOv3 заморожен, Таблица 5.1 сравнивает практически полезные режимы переноса, но не изолирует причинный эффект типа архитектуры. Порогонезависимая пиксельная AP на той же валидационной выборке, напротив, равна 0.8730 ± 0.0021 для DINOv3 и 0.8687 ± 0.0017 для DeerLabV3. Поэтому перевес CNN относится к IoU при зафиксированном пороге 0.5, а не ко всем метрикам ранжирования пикселей. При начальном значении генератора 42 DeerLabV3 со случайной инициализацией и теми же гиперпараметрами получил 0.5442 против 0.6681 с ImageNet-весами; абсолютная разность равна 0.1239. Таким образом, при выбранных гиперпараметрах предварительное обучение заметно улучшает результат DeerLabV3. Однако для модели со случайной инициализацией гиперпараметры отдельно не подбирались, поэтому этот эксперимент не показывает наилучший возможный результат обучения с нуля.

Парный бутстреп по 1247 изображениям подтверждает преимущество DeerLabV3 на масштабированной сетке в каждой паре запусков: $+0.0112$ [0.0005; 0.0223], $+0.0155$ [0.0046; 0.0268] и $+0.0245$ [0.0135; 0.0355] для начальных значений 42, 43 и 44 соответственно. Для ImageNet-инициализации против случайной инициализации интервал разности $+0.1239$ равен [0.1094; 0.1391]. При оценке на исходной сетке аннотаций разность DeerLabV3 и DINOv3 в запуске 42 снижается до $+0.0077$, а её интервал $[-0.0212; 0.0373]$ включает ноль. Это показывает, что малая разность между моделями чувствительна к сетке оценки. Этот последний контроль выполнен только для одного запуска и сам по себе не устанавливает рейтинг на исходной сетке.

После фиксации моделей то же практическое сравнение проведено на тестовой выборке. Обе модели по-прежнему получают вход 384×384 . На сетке 384×384 DINOv3 и DeerLabV3 получили соответственно 0.6619 ± 0.0019 и 0.6731 ± 0.0014 IoU поражения; парная разность равна 0.0112 ± 0.0029 . После интерполяции тех же предсказаний к исходному размеру аннотаций результаты составили 0.6591 ± 0.0015 и 0.6804 ± 0.0030 , а разность — 0.0213 ± 0.0032 . Для начальных значений 42, 43 и 44 бутстреп-интервалы разности на исходной сетке равны [0.0043; 0.0307], [0.0097; 0.0367] и [0.0107; 0.0362]. Следовательно, небольшой перевес DeerLabV3 воспроизвёлся во всех трёх тестовых запусках. Сетка оценки влияет на величину разности, но подтверждающая серия не даёт оснований говорить о смене рейтинга моделей по IoU. При этом пиксельная AP на сетке 384×384 составила

0.8845 ± 0.0005 для DINOv3 и 0.8768 ± 0.0014 для DeepLabV3, повторяя различие между порогонезависимым ранжированием и бинарной маской.

Чтобы устранить различие между полным дообучением CNN и замороженным трансформером, в Таблице 5.2 оба энкодера заморожены, а для каждого используется линейный декодер одинаковой архитектуры на общей сетке 24×24 .

Таблица 5.2 – Согласованное линейное зондирование замороженных энкодеров; среднее и выборочное стандартное отклонение по трём запускам.

Энкодер	Всего, млн	Обучаемых	IoU поражения	Пиксельная AP
ResNet-50, ImageNet, сетка 48×48	23.51	4098	0.3703 ± 0.0041	0.6304
ResNet-50, ImageNet, сетка 24×24	23.51	4098	0.3860 ± 0.0044	0.6495
DINOv3 ViT-B/16	85.66	1538	0.5990 ± 0.0011	0.8402

На валидационной выборке парные разности DINOv3 минус ResNet-50 на общей сетке равны 0.2136, 0.2159 и 0.2093; их среднее составляет 0.2129 ± 0.0034 . Парный бутстреп по изображениям дал 95%-е интервалы $[0.1971; 0.2299]$, $[0.1995; 0.2323]$ и $[0.1927; 0.2255]$, ни один из которых не включает ноль. Контроль на исходной сетке признаков ResNet-50 48×48 дал 0.3703 ± 0.0041 , то есть не устранил разрыв и оказался в среднем на 0.0158 хуже варианта 24×24 ; все три интервала этой парной разности также не включают ноль. Таким образом, преимущество DeepLabV3 в основном сравнении не сохраняется при одинаковом режиме адаптации: среди замороженных энкодеров с одинаковым линейным декодером DINOv3 значительно превосходит ResNet-50.

На тестовой выборке согласованные линейные зонды DINOv3 и ResNet-50 получили соответственно 0.6108 ± 0.0008 и 0.3976 ± 0.0039 IoU поражения; пиксельная AP составила 0.8470 ± 0.0005 и 0.6577 ± 0.0012 . Парная разность IoU равна 0.2132 ± 0.0031 , а три бутстреп-интервала — $[0.2032; 0.2254]$, $[0.2047; 0.2267]$ и $[0.1987; 0.2208]$. Крупный разрыв линейных зондов практически без изменения перенёсся с валидационной на тестовую выборку. Таким образом, замороженные признаки DINOv3 гораздо лучше читаются минимальной головой, тогда как DeepLabV3 достигает большего итогового качества после полного дообучения и с более выразительным декодером. Это свидетельство зависимости результата от режима переноса, а не доказательство общего превосходства одной архитектуры. Сравнение также не выравнивает предобучение: цели и объёмы исходных наборов ImageNet и DINOv3 различаются. Среднее время одного 30-эпохового запуска на A100 составило 17.4 минуты для ResNet-50 и 16.7 минуты для DINOv3; заморозка энкодеров делает этот контроль дешёвым, несмотря на различие полного числа параметров.

5.2 Абляции адаптации DINOv3

В Таблице 5.3 используется начальное значение генератора 42; дополнительные запуски 43 и 44 приведены отдельно. Энкодер заморожен, если не указано иное.

Как видно из Таблицы 5.3, в проведённых экспериментах переход от линейного к свёрточному декодеру для ViT-B/16 дал больший прирост IoU, чем увеличение энкодера

Таблица 5.3 – Результаты адаптации DINOv3 на валидационной выборке.

Энкодер	Декодер и режим обучения	IoU поражения
ViT-B/16	линейный, 10 эпох	0.5944
ViT-L/16	линейный, 10 эпох	0.6040
ViT-B/16	свёрточный, 10 эпох	0.6345
ViT-B/16	последний слой, свёрточный, 30 эпох	0.6438
ViT-B/16	четыре слоя, свёрточный, 30 эпох	0.6569

с ViT-B/16 до ViT-L/16 при линейном декодере: 0.0401 против 0.0096. Таким образом, в рассмотренных конфигурациях усложнение декодера оказалось полезнее увеличения энкодера. ViT-L/16 со свёрточным декодером не тестировался, поэтому этот вывод относится только к приведённым конфигурациям.

Объединение признаков блоков 3, 6, 9 и 12 за 10 эпох почти не отличалось от декодера последнего слоя. При 30 эпохах и косинусном затухании IoU поражения в одном запуске достигло 0.6569. Два дополнительных запуска этой конфигурации дали 0.6538 и 0.6450; среднее по трём начальным значениям генератора равно 0.6519 ± 0.0062 (выборочное стандартное отклонение). Декодер последнего слоя с теми же начальными значениями, числом эпох и расписанием дал 0.6444 ± 0.0007 . Средняя парная разность составляет 0.0075 ± 0.0069 : выигрыш многослойного варианта заметен в запусках 42 и 43, но исчезает в запуске 44. Поэтому результат указывает на небольшой средний эффект, но не позволяет утверждать, что многослойный вариант устойчиво лучше. Для парного t -теста $p \approx 0.20$, а 95%-й доверительный интервал разности равен $[-0.010; 0.025]$.

Замена растяжения на сохранение пропорций с дополнением снизила IoU поражения с 0.6345 до 0.6231, хотя среднее IoU выросло. Правильно классифицированный фон не входит в формулу IoU поражения; вероятная причина — дополнительное уменьшение целевого объекта при вписывании изображения в квадрат. Настройка порога дала лишь 0.0002–0.0017 абсолютного улучшения и не объясняет основной разрыв качества.

Квартили для анализа ошибок построены по доле целевых пикселей после масштабирования маски до 384×384 . Анализ 1247 валидационных изображений показал, что для исходного свёрточного декодера среднее IoU по изображениям равно 0.5352. В квартиле самых малых поражений оно составляет 0.3247, а в квартиле самых больших — 0.7469. Многослойный декодер с косинусным затуханием повысил эти значения до 0.3832 и 0.7687 соответственно и снизил долю изображений с нулевым IoU с 2.25% до 0.80%. Несмотря на улучшение, разрыв между малыми и большими масками остаётся главным обнаруженным режимом ошибки и мотивирует выборку фрагментов и функцию потерь с учётом поражений.

Проверенная повторная выборка на уровне изображений удваивала вес 1979 обучающих изображений из нижнего квартиля по площади маски, не меняя размер эпохи. Она снизила общий IoU поражения с 0.6569 до 0.6498, среднее IoU по изображениям с 0.5766 до 0.5641 и IoU нижнего квартиля с 0.3832 до 0.3649. Одновременно доля изображений с

избыточной сегментацией, где предсказанная площадь превосходит истинную более чем на 25%, выросла с 26.9 до 29.7%. Следовательно, повторение целого изображения не решает проблему пространственного разрешения малой области; этот вариант зафиксирован как отрицательный результат.

Парный бутстреп многослойного и однослойного декодеров дал разности +0.0131 [0.0040; 0.0222], +0.0096 [0.0008; 0.0186] и −0.0001 [−0.0091; 0.0090] для трёх запусков. Тем самым бутстреп уточняет, но не отменяет межзапусковую неустойчивость: в третьем запуске эффекта нет.

5.3 Влияние разрешения и сетки оценки

Таблица 5.4 – DINOv3 при разных входных разрешениях, запуск 42.

Размер	Сетка признаков	IoU, масшт.	IoU, исх.	Время, мин	Память, Гиб
384	24×24	0.6569	0.6194	16.8	—
512	32×32	0.6644	0.6276	24.2	1.72
768	48×48	0.6671	0.6323	50.2	3.31

На исходной сетке аннотаций 512 и 768 px превосходят 384 px на 0.0082 и 0.0129 IoU. Однако 95%-е бутстреп-интервалы равны [−0.0021; 0.0192] и [−0.0049; 0.0323], поэтому по одному запуску нельзя утверждать об устойчивом улучшении. Увеличение от 512 до 768 px даёт лишь 0.0047 IoU на исходной сетке, но более чем удваивает время обучения относительно 512 px. Это указывает на насыщение эффекта и делает 512 px более практичным компромиссом. Поскольку серия выполнена с одним начальным значением генератора, 512 px здесь следует понимать как кандидата для повторной проверки, а не как доказанный оптимум.

5.4 Ручная разметка трудных случаев

Для 64 изображений с наименьшим IoU выполнена многометочная ручная классификация, приведённая в Таблице 5.5.

Таблица 5.5 – Состав 64 худших случаев DINOv3; категории многометочные.

Категория	Число	Доля, %
Много разрозненных очагов	45	70.3
Диффузная или нечёткая граница	22	34.4
Блики, тени, смаз или низкая резкость	15	23.4
Маска менее 0.5%	14	21.9
Поражение не на листе	14	21.9
Смешение с фоном	8	12.5
Возможная проблема аннотации	7	10.9

Основной тип ошибки — пропуск в 24 случаях, избыточная сегментация в 28 и смешанная ошибка в 12. Этот анализ описывает состав худших случаев, а не частоту ошибок во всей валидационной выборке.

5.5 SAM без дообучения

Таблица 5.6 – Качество SAM ViT-B без дообучения с подсказками из эталонной разметки на валидационной выборке. Подсказки получены из истинной маски и не являются автоматическим методом.

Подсказка	IoU пораж.	mIoU	Dice	Пиксельная AP	IoU по снимкам
Положительная точка	0.3624	0.5934	0.5320	0.4689	0.3096
Точная рамка	0.4659	0.6255	0.6357	0.6168	0.4887

Даже точная рамка существенно уступает DINOv3, хотя использует недоступную автоматическому методу информацию из эталонной разметки. Для рамки получена полнота 0.8835 при точности 0.4964: SAM часто захватывает здоровую часть листа или фон внутри подсказки. Следовательно, качество SAM по подсказке из эталона нельзя выдавать за качество автоматической сегментации заболевания.




Рис. 5.1 – Характерные случаи: исходное изображение, эталон, DINOv3 и SAM с рамкой из эталона. Подсказка SAM содержит недоступную автоматической системе информацию и поэтому показана лишь для диагностики.

5.6 Ложные тревоги на здоровых растениях

На 1556 здоровых изображениях из тестовой части PlantWild v1 DINOv3 в среднем отметил как поражение 6.76% площади снимка, DeepLabV3 — 7.72%. Доля изображений с ложной маской более 1% составила 49.4% и 70.8%, а более 5% — 29.5% и 40.5% соответственно. Этот внешний набор отличается от PlantSeg, поэтому числа одновременно отражают ложные тревоги и сдвиг домена. Обе модели без дополнительной калибровки и доменной адаптации не готовы к скринингу здоровых растений из этого внешнего набора.

5.7 Эффективность использования разметки

Для первой кривой качества использовались вложенные подмножества из 80, 396, 792, 1979 и 3958 полностью размеченных изображений, что соответствует 1, 5, 10, 25 и 50% обучающей выборки. Во всех экспериментах за эпоху обрабатывалось 7916 примеров с повторением элементов малых подмножеств. Поэтому число шагов оптимизатора совпало с обучением на полной выборке; менялось только разнообразие доступной разметки. Тестовое разбиение не использовалось.

Таблица 5.7 – IoU поражения на валидационной выборке при разных бюджетах разметки, начальное значение генератора 42.

Доля	Изображения	Случайный	Стратифицированный	Удалённые	Кластеры
1%	80	0.4888	0.5256	0.5124	—
5%	396	0.5833	0.5850	0.5685	—
10%	792	0.6047	0.6054	0.5906	0.6006
25%	1979	0.6244	0.6246	0.6179	0.6216
50%	3958	0.6388	0.6361	0.6316	—
100%	7916	0.6569	0.6569	0.6569	—




Рис. 5.2 – Кривые эффективности разметки при фиксированном числе шагов. Пунктиром показан уровень 0.6241 — 95% от IoU, полученного при обучении на всей доступной разметке.

В одном запуске случайный и стратифицированный отбор пересекают уровень 95% качества полного набора при 25% масок. Однако запас над порогом составляет только 0.0003–0.0005 и намного меньше межзапускового разброса, поэтому это не следует трактовать как гарантированный порог. Площадь под кривой по линейной оси 1–100% также не используется: общая точка 100% доминирует в ней. По логарифму бюджета на интервале 1–50%, без общей конечной точки, нормированная площадь равна 0.8854, 0.8976 и 0.8788 для случайного, стратифицированного и жадного отбора соответственно. На интервале 1–25% значения равны 0.8690, 0.8843 и 0.8632.

Сферический k -means проверен только в ключевых точках 10 и 25%, поэтому площадь под кривой для него не вычисляется. В запуске 42 представители кластеров дали 0.6006 и 0.6216: лучше жадного отбора крайних точек, но хуже случайного и стратифицированного отбора.

Таблица 5.8 – Повторы ключевых бюджетов; среднее IoU поражения и выборочное стандартное отклонение по трём запускам.

Бюджет	Случайный	Стратифицированный	Удалённые	Кластеры
10%	0.6016 ± 0.0067	0.6031 ± 0.0025	0.5857 ± 0.0061	0.6051 ± 0.0064
25%	0.6218 ± 0.0064	0.6243 ± 0.0028	0.6121 ± 0.0051	0.6236 ± 0.0037

Стратификация отличается от случайного отбора лишь на +0.0015 при 10% и +0.0025 при 25%, то есть меньше межзапускового разброса. Жадный отбор наиболее удалённых изображений хуже случайного во всех шести парных сравнениях; средняя разность равна −0.0159 при 10% и −0.0097 при 25%. Представители кластеров лучше жадного отбора во всех шести сравнениях, в среднем на +0.0194 и +0.0115. Однако их разность со случайным отбором равна лишь +0.0035 и +0.0018, а со стратифицированным — +0.0020 и −0.0008; знаки отдельных пар меняются. Следовательно, сферический k -means устраняет провал выбора выбросов, но не демонстрирует устойчивого выигрыша над сильными простыми базами.

При нормировке каждого 25%-запуска на обучение на полной выборке с тем же начальным значением стратифицированный отбор сохраняет не менее 95% качества в трёх случаях из трёх, случайный и кластерный — в двух, а жадный отбор наиболее удалённых — ни в одном. Средние доли равны 95.78, 95.39, 95.66 и 93.90% для стратифицированного, случайного, кластерного и жадного методов соответственно. В этих запусках стратифицированный отбор оказался наиболее надёжным. Однако трёх повторов недостаточно, чтобы утверждать, что при 25% разметки он всегда сохранит не менее 95% качества.

Медианная доля маски почти не меняется между методами. Представители кластеров сохраняют распределения болезней и растений примерно на уровне случайного отбора и тем самым избегают сильного смещения жадного метода, но уступают стратификации по известной метке заболевания. Жадный отбор наиболее удалённых объектов увеличивает TV с 0.139 до 0.224 по болезням и с 0.071 до 0.172 по растениям. По домену исходной ссылки расстояние растёт с 0.307 до 0.356, несмотря на большее число представленных доменов

Таблица 5.9 – Состав 10%-х подмножеств в запуске 42. TV — полное вариационное расстояние до распределения всей обучающей выборки.

Метод	Болезни	Источники	TV болезней	TV растений	TV источников	Медиана маски
Случайный	112	288	0.139	0.071	0.307	0.138
Стратифицированный	112	282	0.023	0.013	0.303	0.139
Наиболее удалённые	107	305	0.224	0.172	0.356	0.143
Представители кластеров	109	307	0.129	0.072	0.316	0.139

(305 против 288): редкие источники получают непропорционально большой вес. На Рисунке 5.3 жадный метод часто выбирает необычные органы, крупные планы и искусственный фон. Следовательно, глобальный дескриптор кодирует композицию и источник изображения наряду с патологией, а максимизация покрытия пространства признаков предпочитает выбросы.




Рис. 5.3 – Первые 16 изображений при случайном отборе (сверху) и жадном отборе наиболее удалённых изображений (снизу), бюджет 10%.

6 Обсуждение и практические рекомендации

Полученные результаты позволяют отделить эффекты, важные на практике, от изменений внутри межзапускового шума. Для внешнего контекста в независимом репозитории с экспериментами на PlantSeg при 384 px приведены 0.646 IoU поражения для DeepLabV3+, 0.682 для SegFormer и 0.701 для SegNeXt [19]. Эти числа показывают достижимый порядок качества, но не являются прямым рейтингом: код, предобработка, веса и протоколы оценки различаются.

1. Полученные результаты не подтверждают общего превосходства одного класса архи-

текстур над другим: соотношение качества зависит от режима адаптации. При входе 384×384 полностью дообученный DeepLabV3 немного сильнее замороженного DINOv3 со свёрточным декодером, зато при одинаковой линейной голове замороженные признаки DINOv3 значительно сильнее признаков ResNet-50. Если допустимо полное дообучение, DeepLabV3 является более быстрым и немного более точным практическим вариантом; при малом числе обучаемых параметров DINOv3 даёт существенно более сильное готовое представление. Более высокая пиксельная AP DINOv3 при меньшем IoU дополнительно показывает, что вывод зависит от выбранной рабочей точки, хотя выполненная настройка порога дала слишком малый прирост, чтобы менять основной протокол.

2. Для замороженного DINOv3 переход от линейного к небольшому свёрточному декодеру дал наиболее крупный контролируемый прирост. Объединение четырёх слоёв при одинаковом длительном обучении дало менее 0.01 IoU и пока не подтверждено статистически; его нельзя рекомендовать без оговорки.
3. При сокращении разметки равномерная случайная выборка является сильной точкой отсчёта. Стратификация по известной метке заболевания уменьшает смещение состава набора, но не даёт устойчивого прироста качества более 0.003. Она полезна как простая страховка при малом бюджете, а не как новый метод активного обучения.
4. Жадный отбор наиболее удалённых глобальных дескрипторов не следует применять без защиты от выбросов. Он нарушил распределение болезней и растений и уступил случайному отбору во всех повторённых сравнениях. Представители сферического k -means сохранили состав выборки лучше и вернули качество к уровню случайного и стратифицированного отбора, но не превзошли их устойчиво. Следующий метод должен учитывать неопределённость или локальные паттерны поражения, а не только глобальную геометрию признаков.
5. SAM без дообучения пригоден как интерактивный диагностический инструмент, но даже точная рамка из эталона не превращает его в детектор заболевания. Сравнить этот режим с автоматической моделью как равноправные системы некорректно.
6. При дальнейшей оптимизации следует проверять 512 px в повторных запусках и выбор фрагментов с поражением: рост разрешения в одном запуске не подтверждён бутстрепом, тогда как разрыв между нижним и верхним квартилями площади маски значительно больше эффектов тонкой настройки декодера.

Измерение в Таблице 6.1 не включает чтение и предобработку данных. При одиночном входе латентность DINOv3 на A100 почти не изменилась между разрешениями, но пик памяти и время обучения растут. DeepLabV3 быстрее на 26% по латентности, но при обучении обновляет 39.63 млн параметров против 7.08 млн у DINOv3.

Таблица 6.1 – Скорость модельного инференса на NVIDIA A100 при размере пакета 1; 20 прогревочных и 100 измеряемых проходов.

Модель	Размер	Мс/изобр.	Изобр./с	Пик памяти, МиБ
DeepLabV3-ResNet50	384	8.27	121.0	202
DINOv3 ViT-B/16	384	11.18	89.4	444
DINOv3 ViT-B/16	512	11.24	89.0	475
DINOv3 ViT-B/16	768	11.01	90.8	583

Код экспериментов хранит полную фактическую конфигурацию, версию окружения, историю обучения, лучшую контрольную точку, число параметров, время и пиковое потребление памяти. Полные тяжёлые артефакты остаются на вычислительной машине, а протоколы и итоговые таблицы фиксируются в репозитории.

7 Ограничения

Бинарная постановка не различает 115 заболеваний и не проверяет гипотезу о том, насколько признаки базовых моделей пригодны для их узкоспециализированной диагностики. Для этого потребуется отдельное многоклассовое сравнение с предметно-специализированными моделями. Работа исследует перенос весов с общего домена изображений на PlantSeg, но не реализует отдельный алгоритм неконтролируемой адаптации между аграрными наборами; это ограничивает интерпретацию формулировки темы.

В используемом разбиении PlantSeg с масками нет здоровых изображений, поэтому основной протокол сам по себе не оценивает специфичность. Внешняя проверка на здоровой части PlantWild частично закрывает этот пробел, но смена набора данных не позволяет отделить ложную тревогу от общего сдвига домена. Высокая частота ложных тревог показывает, что обычный перенос весов сам по себе не даёт устойчивости к смене аграрного набора. Результаты на одном PlantSeg также не гарантируют переносимость на другой сенсор или аграрный домен.

В практическом сравнении семейств DeepLabV3 дообучается целиком, тогда как энкодер DINOv3 заморожен: это сравнение двух практических режимов переноса, но разность нельзя приписывать только архитектуре CNN или трансформера. Согласованное линейное зондирование устраняет различие в режиме адаптации и пространственной сетке, но не выравнивает цель и масштаб предобучения ResNet-50 и DINOv3. Контроль DeepLabV3 со случайной инициализацией сохраняет гиперпараметры ImageNet-варианта, чтобы изолировать начальные веса, но не является отдельно настроенной верхней оценкой обучения с нуля. Основные сравнения повторены трижды, тогда как разрешение, SAM и обучение CNN с нуля проверены только при одном начальном значении генератора; выводы по этим веткам являются менее устойчивыми.

Наконец, полностью размеченное изображение используется как единица стоимости, хотя реальное время аннотации зависит от площади и сложности границ. Методы отбора сравниваются только в режиме холодного старта, без цикла активного обучения. Подсказки для SAM содержат информацию из истинной маски и поэтому являются диагностической верхней оценкой качества по подсказке, а не автоматическим методом поиска заболевания.

8 Заключение

В работе построен единый воспроизводимый протокол для сравнения свёрточной DeepLabV3-ResNet50, трансформерной DINOv3 и SAM в задаче бинарной сегментации поражений PlantSeg и исследована зависимость результата от режима переноса. ImageNet-инициализация DeepLabV3 дала крупный выигрыш над случайной инициализацией в фиксированном режиме. При входе 384×384 полностью дообученный DeepLabV3 немного превзошёл DINOv3 с замороженным энкодером: на подтверждающей тестовой выборке разность на исходной сетке составила 0.0213 ± 0.0032 , и все три бутстреп-интервала исклю-

чили ноль. При одинаковом линейном зондировании замороженных энкодеров направление результата изменилось: DINOv3 превзошёл ResNet-50 на 0.2129 ± 0.0034 IoU на валидационной выборке и на 0.2132 ± 0.0031 на тестовой. Следовательно, готовые признаки DINOv3 существенно лучше читаются минимальным декодером, но это не является доказательством общего превосходства трансформеров: режим и источник предобучения также различаются. У DINOv3 переход от линейного к свёрточному декодеру дал наиболее крупный контролируемый прирост, тогда как эффект чтения четырёх слоёв вместо последнего был мал и зависел от запуска.

Увеличение разрешения DINOv3 с 384 до 768 px повысило точечную оценку IoU, но в единственном запуске доверительный интервал разности включил ноль, а время обучения выросло втрое. Анализ 64 худших случаев показал, что проблема не сводится к одному масштабу: доминируют разрозненные очаги, нечёткие границы и сложные условия съёмки. SAM без дообучения даже с рамкой из эталона уступил автоматическим моделям, а внешняя проверка на здоровых изображениях выявила высокую частоту ложных тревог у обоих семейств и необходимость отдельной доменной адаптации.

В условиях ограниченной разметки 25% изображений в среднем сохранили около 95% качества полной выборки. Простая стратификация лишь слегка стабилизировала результат, а жадное покрытие пространства признаков ухудшило качество из-за перевеса выбросов. Представители кластеров устранили этот провал, но лишь сравнялись с простыми базами. Таким образом, для данной задачи сильная случайная точка отсчёта и анализ состава подмножеств важнее формальной сложности эвристики отбора. В целом качество в этой задаче зависит не только от выбора CNN или трансформера, но и от того, дообучается ли энкодер, какой декодер используется и какие изображения входят в размеченное подмножество.

Список использованных источников

- [1] Oriane Siméoni, Huy V. Vo, Maximilian Seitzer и др. «DINOv3». В: *arXiv preprint arXiv:2508.10104* (2025). URL: <https://arxiv.org/abs/2508.10104> (дата обр. 14.09.2026).
- [2] Alexander Kirillov, Eric Mintun, Nikhila Ravi и др. «Segment Anything». В: *Proceedings of the IEEE/CVF International Conference on Computer Vision*. 2023, с. 4015—4026. DOI: [10.1109/ICCV51070.2023.00371](https://doi.org/10.1109/ICCV51070.2023.00371).
- [3] Sharada P. Mohanty, David P. Hughes и Marcel Salathé. «Using Deep Learning for Image-Based Plant Disease Detection». В: *Frontiers in Plant Science* 7 (2016), с. 1419. DOI: [10.3389/fpls.2016.01419](https://doi.org/10.3389/fpls.2016.01419).
- [4] Tianqi Wei, Zhi Chen, Xin Yu, Scott Chapman, Paul Melloy и Zi Huang. «A Large-Scale In-the-wild Dataset for Plant Disease Segmentation». В: *Scientific Data* 13 (2026), с. 205. DOI: [10.1038/s41597-025-06513-4](https://doi.org/10.1038/s41597-025-06513-4).

- [5] Tianqi Wei, Zhi Chen, Xin Yu, Scott Chapman, Paul Melloy и Zi Huang. «PlantSeg: A Large-Scale In-the-wild Dataset for Plant Disease Segmentation». B: *arXiv preprint arXiv:2409.04038* (2024). URL: <https://arxiv.org/abs/2409.04038> (дата обр. 16.09.2026).
- [6] Tianqi Wei, Zhi Chen, Zi Huang и Xin Yu. «Benchmarking In-the-Wild Multimodal Plant Disease Recognition and a Versatile Baseline». B: *Proceedings of the 32nd ACM International Conference on Multimedia*. 2024. URL: <https://arxiv.org/abs/2408.03120> (дата обр. 16.09.2026).
- [7] Liang-Chieh Chen, George Papandreou, Florian Schroff и Hartwig Adam. «Rethinking Atrous Convolution for Semantic Image Segmentation». B: *arXiv preprint arXiv:1706.05587* (2017). URL: <https://arxiv.org/abs/1706.05587>.
- [8] Liang-Chieh Chen, Yukun Zhu, George Papandreou, Florian Schroff и Hartwig Adam. «Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation». B: *Proceedings of the European Conference on Computer Vision*. 2018, с. 801—818.
- [9] Maxime Oquab, Timothée Darcet, Théo Moutakanni и др. «DINOv2: Learning Robust Visual Features without Supervision». B: *Transactions on Machine Learning Research* (2024). URL: <https://arxiv.org/abs/2304.07193>.
- [10] Tianrun Chen, Lanyun Zhu, Chaotao Deng и др. «SAM-Adapter: Adapting Segment Anything in Underperformed Scenes». B: *Proceedings of the IEEE/CVF International Conference on Computer Vision Workshops*. 2023, с. 3367—3375.
- [11] Jun Ma, Yuting He, Feifei Li, Lin Han, Chenyu You и Bo Wang. «Segment Anything in Medical Images». B: *Nature Communications* 15.1 (2024), с. 654. DOI: [10.1038/s41467-024-44824-z](https://doi.org/10.1038/s41467-024-44824-z).
- [12] Lei Ke, Mingqiao Ye, Martin Danelljan, Yifan Liu, Yu-Wing Tai, Chi-Keung Tang и Fisher Yu. «Segment Anything in High Quality». B: *Advances in Neural Information Processing Systems*. Т. 36. 2023.
- [13] Renrui Zhang, Zhengkai Jiang, Ziyu Guo, Shilin Yan, Junting Pan, Hao Dong, Yu Qiao, Peng Gao и Hongsheng Li. «Personalize Segment Anything Model with One Shot». B: *International Conference on Learning Representations*. 2024.
- [14] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu и др. «SAM 2: Segment Anything in Images and Videos». B: *arXiv preprint arXiv:2408.00714* (2024). URL: <https://arxiv.org/abs/2408.00714>.
- [15] Ozan Sener и Silvio Savarese. «Active Learning for Convolutional Neural Networks: A Core-Set Approach». B: *International Conference on Learning Representations*. 2018. URL: <https://openreview.net/forum?id=H1aIuk-RW> (дата обр. 14.09.2026).

- [16] Guy Hach Cohen, Avihu Dekel и Daphna Weinshall. «Active Learning on a Budget: Opposite Strategies Suit High and Low Budgets». В: *Proceedings of the 39th International Conference on Machine Learning*. Т. 162. Proceedings of Machine Learning Research. 2022, с. 8175—8195. URL: <https://proceedings.mlr.press/v162/hachohen22a.html> (дата обр. 14.09.2026).
- [17] Sudhanshu Mittal, Maxim Tatarchenko, Özgün Çiçek и Thomas Brox. «Parting with Illusions about Deep Active Learning». В: *arXiv preprint arXiv:1912.05361* (2019). URL: <https://arxiv.org/abs/1912.05361>.
- [18] Prateek Munjal, Nasir Hayat, Munawar Hayat, Jamshid Sourati и Shadab Khan. «Towards Robust and Reproducible Active Learning Using Neural Networks». В: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2022, с. 223—232.
- [19] Dmitry Bakin. *Plant Diseases Segmentation: Experiment Reports and Code*. 2026. URL: <https://github.com/dfbakin/plant-diseases-segmentation> (дата обр. 14.09.2026).